


Aula 3

Monday, March 9, 2026 9:58 AM

Classificação Binária


↳ Algoritmos assumem que os dados de entrada estão em $\mathbb{R}^d$
 vetor



$$y = \begin{cases} \text{classe +} & \text{se } f(x) > 0 \\ \text{classe -} & \text{se } f(x) < 0 \end{cases} \quad f(x) = 0$$

↳ Fronteira

E quando a entrada é uma imagem?



1. Representação

conjunto de variáveis $x_1, \dots, x_d$
 valores numéricos ou categóricos
 Uma instância $x \in \mathbb{R}^d$

Algoritmos generativos x discriminativos

X : espaço de entrada
 Y : " " saída
 $f: X \rightarrow Y$: função de X em Y

P_X : distribuição de probabilidade sobre X
 P_Y : " " " " " Y
 $P_{X,Y}$: " " " " sobre $X \times Y$

$$P(x|y) = \frac{P(x,y)}{P(y)} \Rightarrow P(x,y) = P(y) \cdot P(x|y)$$

$$P(y|x) =$$

Exemplos

↳ Sei altura

↳ Da p (altura) para a partir da altura?

$$P(x|y=M) \cdot P(y=M)$$

$$P(x|y=F) \cdot P(y=F)$$

Teorema de Bayes em classificação

$$\underbrace{P(y_j|x)}_{\text{posteriori}} = \frac{\underbrace{P(y_j)}_{\text{priori}} \cdot \underbrace{P(x|y_j)}_{\text{verossimilhança}}}{\underbrace{\sum_{i=1}^n P(y_i) \cdot P(x|y_i)}_{\text{evidência } p(x)}} = \frac{P(y_j) \cdot P(x|y_j)}{p(x)}$$

Classificação

$$y^* = \arg \max \{ P(y|x) \mid y \in \{F, M\} \}$$

$$P(y|x) = \frac{P(y) \cdot P(x|y)}{p(x)}$$

Quando Distribuições não são contínuas

↳ Se termos dados

↳ Método paramétrico responde $p(x|y)$ gaussiano

$$p(x|y=F) = \frac{1}{\sigma_F \sqrt{2\pi}} e^{-\frac{(x-\mu_F)^2}{2\sigma_F^2}}$$

Muitas vezes a fronteira é o nosso interesse

$$h(x) = P(y=M|x) - P(y=F|x) \rightarrow \text{Fronteira}$$

$$\hat{y} = \begin{cases} M & h(x) > 0 \\ F & h(x) < 0 \\ \text{tanto faz} & h(x) = 0 \end{cases}$$

Pode ser outra função simples

$$h(x) = ax + b$$

$h \rightarrow$ função discriminadora

Generativa $\rightarrow$ usando distribuições de probabilidade

Regressão Logística

- ↳ Classificação
- ↳ Encontrar fronteira

Como encontrar uma fronteira?

- ↳ Minimizar erro de classificação

Intuição 1

- ↳ $y = +1$ ou $y = -1$
- ↳ hiperplano $h(x) = w_0 + w_1 x_1 + \dots + w_d x_d$
- ↳ Problemas
 - ↳ outliers desbalanceados a rede
 - ↳ classes desbalanceadas (omitir $y = +1$ ou $y = -1$)

Conclusão 1

- ↳ Até possível calcular fronteira
- ↳ Solução muito dependente dos dados X .

Regressão Logística

$$z = w^t x \quad z \in \mathbb{R}$$

$$\sigma(z) = \frac{1}{1 + e^{-z}} = \frac{e^z}{e^z + 1}$$

$$h(x) = \sigma(w^t \tilde{x})$$

- ↳ família de hipótese

Formulação do Problema

$$Y = \{0, 1\}$$

Função alvo

- ↳ $p(x) = P(y=1|x)$
- ↳ Substituir $p(x)$ por $\hat{y}$
- ↳ $\hat{y} = 1 \Leftrightarrow p(y=1|x) > 0,5$

Função de perda

$$P(X, Y)$$

$$P(x, y) = P(x) \cdot P(y|x)$$

Vamos assumir x, y independentes e identicamente distribuídas.

$$P(D) = \prod_{n=1}^N P(x^n, y^n) \quad \text{distribuídos}$$

$$= \prod_{n=1}^N P(x^n) \cdot P(y^n | x^n)$$

$$P(y|x) = P(y=1|x)^y \cdot P(y=0|x)^{1-y}$$

$$= P(y=1|x)^y \cdot [1 - P(y=1|x)]^{1-y}$$

$$P(y|x) = f(x)^y \cdot (1 - f(x))^{1-y}$$

Estimção por Máxima Verossimilhança

$$L(D|h) = \prod_{n=1}^N P(x^n) h(x)^y [1 - h(x)]^{1-y}$$

↓
pode ser considerado
uma constante, pois não influencia

$$\hat{p}_x = h(x) = \sigma(w^T x)$$

$$L(w) = \prod_{(x,y) \in D} (\hat{p}_x)^y \cdot (1 - \hat{p}_x)^{1-y}$$

Regra prob. conjunta

Regra máx. verossimilhança

Cross Entropy

Máximizar máxima verossimilhança

= minimizar a função de perda

$$L(w) = -\frac{1}{N} \sum_{n=1}^N y^{(n)} \ln \hat{p}_x^{(n)} + (1 - y^{(n)}) \cdot \ln(1 - \hat{p}_x^{(n)})$$

